

Detecção de Fake News com LLMs Utilizando Sinais de Credibilidade

Rafael Lima Figueiredo^{1*}; Juliano Domingues da Silva²

¹ Graduado em Engenharia de Produção pela UFMG. Belo Horizonte, Minas Gerais, Brasil

² Universidade Estadual de Maringá. Professor Adjunto do Departamento de Administração. Av. Colombo, Jardim
Universitário, Maringá - Paraná, Brasil

*autor correspondente: rafaelfigueiredo1@gmail.com

Detecção de fake news com LLMs utilizando sinais de credibilidade

Resumo

O aumento do volume de informações geradas diariamente dificultou a verificação manual da veracidade dos conteúdos, o que exigiu a implementação de métodos automáticos e robustos para o monitoramento e classificação das notícias. Este estudo apresentou como objetivo geral investigar a eficácia de modelos de linguagem de larga escala (LLMs) na detecção de fake news, destacando seu potencial não apenas para interpretar o contexto semântico dos textos, mas também para incorporar sinais de credibilidade. A pesquisa adotou uma abordagem quantitativa e experimental, estruturada para comparar o desempenho de diferentes metodologias, especificamente avaliando a eficácia de modelos que integraram 18 sinais de credibilidade em relação a abordagens de classificação sem treinamento prévio por meio da análise de métricas como precisão e F1-score. Os resultados indicaram que ambas as abordagens apresentaram desempenho semelhante ao de outros trabalhos baseados em classificação sem exemplos, embora o modelo que utilizou sinais de credibilidade como variáveis preditoras tenha obtido desempenho inferior, possivelmente devido à inconsistência na rotulagem gerada automaticamente a partir do prompt utilizado. Concluiu-se que, apesar do potencial dos LLMs, há necessidade de refinamento nos métodos de incorporação de sinais de credibilidade para aprimorar a qualidade dos dados e viabilizar aplicações em larga escala.

Palavras-chave: Rotulagem Automatizada, Heurísticas de Credibilidade, Modelos de Linguagem de Larga Escala

Fake News Detection with LLMs Using Credibility Signals

Abstract

The increasing volume of information generated daily has made it difficult to manually verify content accuracy, which has necessitated the implementation of automatic and robust methods for monitoring and classifying news. This study aimed to investigate the effectiveness of large language models (LLMs) in detecting fake news, highlighting their potential not only to interpret the semantic context of texts but also to incorporate credibility signals. The research adopted a quantitative and experimental approach, structured to compare the performance of different methodologies, specifically evaluating the effectiveness of models that integrated 18 credibility signals in relation to zero-shot approaches through the analysis of metrics such as accuracy and F1-score. The results indicated that both approaches showed performance similar to that of other works based on zero-shot classification, although the model that used credibility signals as predictive variables achieved lower performance, possibly due to inconsistency in the labeling automatically generated from the prompt used. It was concluded that, despite the potential of LLMs, there is a need for refinement in the methods of incorporating credibility signals to enhance data quality and enable large-scale applications.

Keywords: Automated Labeling, Credibility Heuristics, Large-Scale Language Models

Introdução

A detecção de fake news emergiu como uma área crítica na interseção entre ciência da computação e jornalismo, impulsionada pela crescente preocupação com a rápida disseminação de informações falsas em plataformas digitais. Em eleições recentes, como a norte-americana de 2016, boatos sobre supostos apoiadores do candidato foram amplamente compartilhados, influenciando percepções eleitorais e gerando debates acalorados nas redes sociais. No Brasil, durante o pleito de 2018, grupos organizados utilizaram listas de transmissão no WhatsApp para disseminar notícias falsas sobre urnas eletrônicas, chegando a mobilizar milhares de usuários em correntes de desinformação. Em crises sanitárias, como a pandemia de COVID-19, boatos sobre tratamentos milagrosos levaram ao desabastecimento de medicamentos, pânico social e decisões médicas inadequadas. Esses episódios ilustram o impacto real da desinformação sobre decisões individuais e políticas públicas, reforçando a urgência de métodos automáticos e robustos para verificação de fatos e classificação de conteúdo.

De acordo com Shu et al. (2020), o aumento do volume de informações geradas diariamente dificultou a verificação manual da veracidade dos conteúdos, exigindo métodos automáticos e robustos para monitoramento e classificação. Modelos de linguagem de larga escala [LLMs] têm demonstrado potencial significativo nesse campo, não apenas pela sua capacidade de interpretar o contexto semântico de textos, mas também por incorporar sinais de credibilidade, um dos avanços mais promissores na detecção de notícias falsas (Horne & Adalı, 2017). Esses sinais — como a confiabilidade das fontes e o histórico de precisão dos autores — são fundamentais para a classificação da veracidade, contribuindo para abordagens mais sofisticadas e menos suscetíveis a vieses comuns em sistemas de aprendizado supervisionado (Harris, 1997).

Por exemplo, considere a seguinte notícia fictícia:

"Renomado cientista afirma que água com limão cura COVID-19; governo ignora estudos e favorece grandes laboratórios."

Mesmo antes de checar a veracidade factual, é possível identificar diversos sinais de credibilidade questionáveis no texto. A citação de especialista é vaga ("renomado cientista" sem nome), o título utiliza linguagem sensacionalista, há um claro viés emocional contra o governo e um tom de conspiração ao sugerir favorecimento a laboratórios. Além disso, a falta de evidências documentadas, como estudos ou fontes verificáveis, reforça a desconfiança. Esse exemplo ilustra como os sinais de credibilidade podem atuar como heurísticas iniciais para avaliação de confiabilidade, especialmente em contextos nos quais o volume de informações torna inviável a checagem manual de todos os dados.

A literatura recente apresenta metodologias como o Knowledge Informed Fake News Detection, que combina grandes modelos de linguagem com bases de conhecimento estruturadas para enriquecer o processo de classificação e verificação de notícias falsas (Zhou Zhou et al., 2021). Nessa abordagem, o modelo não só analisa o conteúdo textual, mas também integra informações adicionais de bases de conhecimento, tais como fatos e entidades verificados, contribuindo para uma análise mais precisa. Contudo, essas abordagens, embora eficazes, são computacionalmente custosas devido à necessidade de

múltiplas consultas a fontes externas e ao processamento de grandes volumes de dados (Shu et al., 2020). Além disso, a execução de LLMs com informações adicionais requer infraestrutura robusta e otimização contínua, tornando o uso dessas técnicas mais desafiador para implementações em larga escala e aplicações em tempo real (Chen et al., 2023).

A preocupação com a detecção eficiente e confiável de fake news é essencial tanto do ponto de vista acadêmico quanto prático, dada a extensão dos impactos sociais, políticos e econômicos da desinformação. No âmbito prático, plataformas de mídia social, organizações de notícias e entidades governamentais são diretamente afetadas, uma vez que a proliferação de informações falsas compromete a confiança pública e influencia decisões individuais e coletivas (Allcott & Gentzkow, 2017). Por exemplo, durante períodos eleitorais, algoritmos de detecção em tempo real têm sido empregados para identificar perfis e conteúdos suspeitos, contribuindo para um ambiente de debate mais seguro e transparente. Em crises de saúde pública, como observamos em recentes pandemias, a rápida identificação de desinformação se mostrou crucial para a disseminação de informações corretas e para o combate ao pânico social. Além disso, a aplicação de técnicas de machine learning e inteligência artificial em plataformas como X e Facebook destaca a importância de modelos que conciliem precisão e eficiência computacional, permitindo a análise de grandes volumes de dados em tempo real. Com isso, o desenvolvimento de um modelo de detecção mais acessível e otimizado não só atende à demanda por maior segurança informacional, mas também fortalece a credibilidade das plataformas e contribui significativamente para o avanço teórico e prático na área de processamento de linguagem natural e análise de dados.

Diante desse cenário, este trabalho tem como objetivo desenvolver e avaliar um modelo para detecção de fake news que explore o potencial dos modelos de linguagem de larga escala aliados à utilização de sinais de credibilidade, visando aprimorar a precisão da classificação sem comprometer a eficiência computacional. Diferentemente de abordagens convencionais baseadas exclusivamente em aprendizado supervisionado ou redes neurais tradicionais, a proposta deste estudo busca integrar sinais de credibilidade e informações complementares de forma otimizada, reduzindo a dependência de grandes volumes de dados rotulados. Dessa forma, este trabalho contribui para o desenvolvimento de métodos mais robustos e escaláveis, ampliando as possibilidades de aplicação prática na mitigação da desinformação em larga escala.

Material e Métodos

Delineamento da Pesquisa

Este estudo adota uma abordagem quantitativa e experimental, estruturada para comparar o desempenho de diferentes metodologias na detecção de fake news. Especificamente, investigamos a eficácia de modelos que incorporam sinais de credibilidade em relação a abordagens de aprendizado sem exemplos, analisando métricas como precisão e F1-score. Essa escolha metodológica permite avaliar de forma sistemática o impacto dessas estratégias na classificação de notícias falsas e medir sua viabilidade para aplicações em larga escala.

Os sinais de credibilidade são heurísticas mensuráveis que auxiliam na avaliação da confiabilidade das informações. Eles podem estar relacionados a diferentes aspectos do texto, como o título do artigo (Horne and Adali, 2017) o estilo de escrita (Afroz et al., 2012), a

presença de viés (Dufraisie et al., 2022) ou o uso de linguagem emocional (Giachanou et al., 2019). O W3C Credible Web Community Group, organização dedicada ao desenvolvimento de diretrizes para aumentar a credibilidade da informação na web, documentou mais de 200 sinais de credibilidade. Para cada um deles, existe uma definição, que foi utilizada para criar a pergunta de cada sinal.

Para este estudo, foram selecionados 18 sinais, levando em conta sua relevância teórica e a disponibilidade dessas informações na base de dados utilizada. Os sinais utilizados foram: Chamada para Ação, Citação de Documentos, Citação de Especialistas, Impolidez, Evidência, Perspectiva Pessoal, Organização de Baixa Credibilidade, Afirmações Explicitamente Não Verificadas, Valência Emocional, Grafia Incorreta, Credibilidade da Fonte, Sensacionalismo, Linguagem Polarizada, Viés, Tom Informal, Incivilidade, Reportado por Outras Fontes e Inferência.

Fontes de Dados

Para garantir a robustez do estudo, foram selecionadas as bases de dados FA-KES (Abu et al., 2019) e Fake.Br Corpus (Monteiro et al., 2018). A FA-KES oferece uma coleção ampla de notícias sobre a guerra na Síria. Já a Fake.Br Corpus, possui notícias escritas em português brasileiro, com uma ampla variedade de temas. A utilização dessas duas fontes proporciona uma diversidade de exemplos e ajuda a verificar a generalização dos métodos em diferentes contextos culturais e temáticos, assim como a diferença em duas línguas diferentes.

Para evitar redundâncias e garantir a diversidade do conjunto de dados, realizamos a deduplicação das notícias baseada na similaridade entre strings. Utilizamos a métrica de similaridade de Levenshtein normalizada (Levenshtein, V. I., 1966) com um limiar de similaridade de 80%. Quando duas notícias ultrapassavam esse limiar, considerávamos uma delas redundante e a removíamos do conjunto de dados.

Ambas as bases são divididas em 70% para treino e 30% para teste. A distribuição de notícias verdadeiras e falsas nas 2 bases estão representadas na tabela 1.

Tabela 1. Distribuição de notícias verdadeiras e falsas por base

	FA-KES		Fake.Br Corpus	
	Treino	Teste	Treino	Teste
Verdadeiro	145	62	140	60
Falso	135	58	140	60

Instrumentos e Ferramentas

Para a implementação dos métodos de análise, foram utilizados os modelos Gemini 1.5-Flash e o DeepSeek-V3. A escolha desses modelos se deve à sua eficácia demonstrada em tarefas de processamento de linguagem natural e à sua capacidade de se adaptarem a diferentes tipos de classificação textual. Além disso, esses modelos possuem estruturas de prompting robustas, que permitem a configuração para tarefas específicas por meio de diferentes instruções. A implementação foi realizada via API, utilizando temperatura igual a 0,1,

utilizando a biblioteca aisuite, que serve como interface para diferentes provedores de LLMs (Yang-aisuite, 2024), tornando o experimento mais modular e replicável.

Classificação sem Treinamento Prévio

Para cada notícia, seu texto era incorporado em um prompt estruturado que definia explicitamente o papel do modelo como um especialista em verificação de fatos, seguido por uma pergunta direta sobre a presença de desinformação ou propaganda. O prompt principal utilizado foi estruturado da seguinte forma:

“Você é um especialista em verificação de fatos. Leia a notícia abaixo e responda: essa notícia contém desinformação ou propaganda? Responda apenas com YES ou NO, e explique brevemente sua justificativa.”

O texto da notícia era inserido logo após essa instrução, como entrada única do modelo. Esse prompt buscava simular a atuação de um verificador humano, com critérios objetivos para identificar conteúdo duvidoso. A notícia era então submetida à API do modelo selecionado.

Após a geração da resposta, um mecanismo de validação baseado em expressão regular verificava imediatamente se a saída começava com "YES" ou "NO", ignorando variações de capitalização e outros caracteres especiais (como asteriscos). Caso a resposta não correspondesse ao padrão esperado, um prompt secundário era acionado automaticamente: este segundo estágio isolava a tarefa de classificação binária, reprocessando a resposta original do modelo através de um novo contexto instrucional focado exclusivamente na categorização.

Rotulagem dos Sinais de Credibilidade

Para fazer a rotulagem dos sinais de credibilidade, foi operacionalizada uma pergunta específica para cada sinal, como por exemplo: “O artigo apresenta alguma evidência ou argumentos para fundamentar suas alegações?” para o sinal de “Evidência”. Essa resposta passava por um mecanismo de validação baseado em expressão regular, que verificava imediatamente se a saída começava com "YES" ou "NO", assim como no passo anterior.

Cada pergunta foi baseada nas definições formais do W3C Credible Web. O texto da notícia era inserido no prompt correspondente, e o modelo deveria responder com "YES", "NO" ou "ABSTAIN". Um exemplo de prompt é:

“Does the article present any supporting evidence or arguments to substantiate its claims?”

Para garantir a consistência da saída, aplicou-se uma expressão regular `^(yes|no|abstain)` (case-insensitive). Caso a resposta não estivesse nesse padrão, era feito um segundo chamado com um prompt simplificado e mais direto. Quando a resposta não tinha esse

formato, um segundo prompt era acionado, nesse caso ela poderia ser classificada em três formas: "YES", "NO" ou "ABSTAIN".

Modelo de Classificação Utilizando os Sinais de Credibilidade como Features

Foi desenvolvido um modelo de classificação supervisionada com o objetivo de detectar desinformação, utilizando os 18 sinais de credibilidade como variáveis de entrada (features). Essas variáveis foram representadas como atributos categóricos, com valores correspondentes às respostas "YES", "NO" e "ABSTAIN", previamente atribuídas pelos modelos de linguagem.

Durante a modelagem, diferentes algoritmos de aprendizado de máquina foram avaliados, sendo o XGBoost o escolhido devido à sua robustez, interpretabilidade e bom desempenho em tarefas de classificação binária.

O conjunto de dados rotulado foi dividido em treino e teste seguindo a proporção original das bases (70% para treino e 30% para teste). A etapa de treinamento contou com validação cruzada 5-fold e a seleção dos hiperparâmetros foi realizada por meio de uma busca em grade (Grid Search), com os seguintes valores:

- learning_rate: [0.05, 0.1, 0.2]
- max_depth: [4, 6, 8]
- n_estimators: [10, 50, 100]

Como métricas de avaliação, foram utilizadas acurácia e F1-score macro, por levarem em consideração tanto a taxa de acertos quanto o equilíbrio entre classes. A escolha do F1-macro se justifica pela necessidade de avaliar o desempenho global do classificador, sem favorecer desproporcionalmente uma das classes.

Essa abordagem permitiu uma comparação sistemática entre os modelos testados e revelou limitações relacionadas à qualidade dos rótulos atribuídos automaticamente aos sinais de credibilidade.

Resultados e Discussão

Classificação sem treinamento Prévio

A tabela 2 apresenta os resultados da classificação sem treinamento prévio em ambas as bases de dados. Os dois modelos têm um desempenho inferior na base FA-KES, com uma acurácia abaixo de 50%, comprovando que modelos de LLMs ainda não são capazes de diferenciar notícias falsas de verdadeiras de forma confiável. Esse resultado se assemelha com o resultado de outros modelos testados na literatura, como o Leite et al. (2023), que obteve 46,2%, 52,7% e 52,3% de acurácia utilizando o GPT-3.5-Turbo, Alpaca-LoRA-30B e OpenAssistant-30B respectivamente.

Tabela 2. Acurácia e F1-score por modelo usando aprendizado sem exemplos

Modelo	FA-KES		Fake.Br Corpus	
	Acurácia	F1-Macro	Acurácia	F1-Macro
Gemini 1.5 Flash	49%	48%	79%	79%
DeepSeek-V3	46%	34%	62%	61%

Fonte: Resultados originais da pesquisa

Para a base do Fake.Br Corpus, a acurácia dos modelos é bem maior, com uma acurácia de 79% para o modelo Gemini 1.5 Flash. Entretanto, não é possível afirmar que esses modelos são eficientes, pois existem outros resultados na literatura como Paixão et al. (2020), que conseguiram resultados de 91,64% de acurácia nessa mesma base utilizando SVM e variáveis do texto como recursos linguísticos, Marcadores de Classe Gramatical e Frequência do Termo – Inversa da Frequência nos Documentos (TF-IDF).

Além disso, devido a natureza desses modelos, não é possível identificar se essas notícias foram utilizadas no seu treinamento, podendo ocorrer um vazamento de dados.

Analisando as matrizes de confusão, Figura 1, percebemos que o modelo da DeepSeek-V3, tinha um viés em classificar todas as notícias como verdadeiras, com destaque de apenas 7 notícias rotuladas como falsa na base FA-KES. Já o modelo do Google, apresentou um balanço maior nessa classificação, conseguindo uma acurácia e F1-Macro maior que o modelo Chinês.




Figura 1. Matriz de Confusão dos modelos Gemini 1.5-Flash e DeepSeek-V3 na base FA-KES

Ao olhar a matriz de confusão da base brasileira, Figura 2, temos um equilíbrio grande entre notícias falsas e verdadeiras classificadas corretamente com o Gemini, com um F1-macro de

79%, com uma ligeira inclinação a identificar FAKE corretamente do que Real. O modelo da DeepSeek ainda teve uma grande tendência de classificar as notícias como reais, mas conseguiu acertar um pouco mais nessa base.




Figura 2. Matriz de Confusão dos modelos Gemini 1.5-Flash e DeepSeek-V3 na base Fake.Br Corpus

Fonte: Resultados originais da pesquisa

Resultados da Rotulagem dos Sinais de Credibilidade

A Figura 3 apresenta os resultados da rotulagem dos sinais de credibilidade de 300 notícias da base FA-KES, no qual vermelho representa “NÃO”, a verde “SIM” e a branca “ABSTENÇÃO”. Analisando os resultados, podemos perceber que alguns sinais têm uma predominância muito alta de “SIM” ou “NÃO”, como no caso do sinal “Chamada para Ação” no modelo Gemini, com 91,43% de “NÃO”.



Figura 3. Classificação dos Sinais de Credibilidade modelo Gemini 1.5-Flash e DeepSeek-V3 na base FA-KES

Fonte: Resultados originais da pesquisa

Além disso, foi feita uma análise de correspondência para identificar se os rótulos eram similares entre os diferentes modelos, com os resultados apresentados na Tabela 3. Nessa análise, tivemos uma correspondência de 65,90%, o que indica que, embora o prompt seja o mesmo, os modelos tiveram respostas bastante diferentes. A correspondência foi mais alta em prompts mais diretos e fáceis de se classificar como “Chamada para Ação” (90,27%) e “Citação de Documentos” (89,82%) e mais baixa em sinais mais subjetivos como “Inferência” (37,61%) e “incivilidade” (47,79%). Ao analisar as respostas específicas ao prompt de “Inferência”, percebemos que o Gemini identifica correlações e causalidades implícitas no texto, como a ocorrência de um ataque de rebeldes e mortes, enquanto o DeepSeek não identifica essa ocorrência na falta de palavras como “devido a isso” ou ocorrência mais explícitas. Por conta da limitação do custo de fazer várias chamadas as APIs, não foi possível fazer um grande refinamento dos prompts para alcançar resultados mais precisos e consistentes.

Tabela 3. Correspondência dos sinais de credibilidade na base X dos modelos Gemini-1.5-Flash e DeepSeek-V3

Indicador	Correspondência
Chamada para Ação	0.902655
Citação de Documentos	0.89823
Citação de Especialistas	0.893805
Impolidez	0.831111
Evidência	0.792035
Perspectiva Pessoal	0.716814
Organização de Baixa Credibilidade	0.693333
Afirmações Explicitamente Não Verificadas	0.676991
Valência Emocional	0.672566
Grafia Incorreta	0.659292
Credibilidade da Fonte	0.628319
Sensacionalismo	0.604444
Linguagem Polarizada	0.597345
Viés	0.522124
Tom Informal	0.50885
Incivilidade	0.477876
Reportado por Outras Fontes	0.408889
Inferência	0.376106

Fonte: Resultados originais da pesquisa

Modelo de Classificação Utilizando os Sinais de Credibilidade como Features

A tabela 2 apresenta os resultados do modelo criado em ambas as bases de dados. Para obter esses resultados, foi treinado um modelo XGBoost. Os melhores parâmetros encontrados no Grid Search foram: taxa de aprendizado igual a 0,1, profundidade máxima igual a 6 e 10 estimadores.

Os resultados foram melhores na Fake.Br Corpus do que na FA-KES, o que é surpreendente, dado que os resultados no aprendizado sem exemplos foram muito melhores na base brasileira. Entretanto, em todos os modelos e bases o resultado ficou muito próximo de 50%, fazendo com que um modelo assim não seja muito eficiente, considerando que ele é bem mais custoso que uma aprendizagem sem exemplos.

Não é possível ter certeza se a utilização desses sinais para a previsão automática de fakes é inútil, dado que a rotulagem criada no passo anterior pode estar incorreta, impossibilitando que o modelo criado tenha um bom desempenho.

Tabela 4. Acurácia e F1-score por modelo usando XGBoost

Modelo	FA-KES		Fake.Br Corpus	
	Acurácia	F1-Macro	Acurácia	F1-Macro
Gemini 1.5 Flash	52%	51%	47%	47%
DeepSeek-V3	57%	57%	54%	54%

Fonte: Resultados originais da pesquisa

Foi feita também uma matriz de correlação de Cramer's V (Cramér, 1946) em que a variável resposta não teve correlação com nenhuma variável preditora, o que explica, em grande parte, o baixo desempenho do modelo. Entretanto, podemos perceber sinais muito correlacionados como "Chamada para Ação" e a "Citação de Documentos" (0,71), Figura 4, e "Afirmações Explicitamente Não Verificadas" e "Evidência" (0,73) na Figura 5, o que pode indicar que podemos filtrar alguns sinais de credibilidade pois eles apresentam a mesma informação.




Figura 4. Matriz de Correlação Cramér's V no modelo Gemini 1.5-Flash




Figura 5. Matriz de Correlação Cramér's V no modelo DeepSeek-V3

Por fim, foi elaborado um gráfico de importância das variáveis, Figura 6, evidenciando que “Credibilidade da Fonte” e “Reportado por Outras Fontes” se destacam significativamente. Esses resultados corroboram hipóteses baseadas na interpretação humana, sugerindo que

os sinais associados à verificação e à confiabilidade das informações desempenham papel relevante no contexto analisado. Entretanto, é importante destacar que a baixa acurácia do modelo apresenta indicações limitadas sobre sua capacidade preditiva. Assim, recomenda-se cautela na interpretação dos resultados e sugere-se a necessidade de refinamentos adicionais na metodologia e na seleção das variáveis, de modo a aprimorar a robustez e a confiabilidade do modelo preditivo.




Figura 6. Importâncias das variáveis no modelo XGBoost usando o input dos sinais de credibilidade do modelo Gemini 1.5-Flash.

Além das limitações técnicas, é fundamental considerar as implicações éticas do uso de LLMs na detecção de fake news. Modelos de linguagem operam como "caixas-pretas" e podem reproduzir vieses presentes nos dados de treinamento, o que levanta preocupações sobre discriminação, censura indevida ou reforço de narrativas enviesadas. A falta de transparência sobre quais dados foram utilizados no treinamento também dificulta a auditoria e a verificação de possíveis vazamentos, especialmente quando os modelos classificam notícias que podem ter sido previamente vistas. Em contextos sensíveis, como o combate à desinformação, essas questões éticas tornam-se ainda mais críticas, exigindo que o uso dessas tecnologias seja acompanhado por mecanismos de supervisão humana, auditoria contínua e transparência do algoritmo para garantir que não sejam utilizadas de forma opaca ou autoritária.

Os resultados obtidos neste estudo demonstram limitações relevantes tanto na classificação sem treinamento prévio quanto na abordagem supervisionada com sinais de credibilidade,

especialmente na base FA-KES. Esse desempenho está alinhado com o observado por Leite et al. (2023), que também relataram acurácia abaixo de 55% ao empregar LLMs em tarefas de classificação sem exemplos. Por outro lado, modelos supervisionados tradicionais, como o SVM utilizado por Paixão et al. (2020), ainda se mostram superiores na Fake.Br Corpus, alcançando acurácia superior a 90% com recursos linguísticos cuidadosamente selecionados. Tais comparações indicam que, apesar do potencial dos LLMs, a sua eficácia na detecção automatizada de desinformação ainda depende fortemente do refinamento dos prompts e da curadoria dos dados utilizados para treinamento ou avaliação. Além disso, o uso de sinais de credibilidade como variáveis preditoras, embora teoricamente promissor (Horne & Adali, 2017), apresentou desempenho modesto neste experimento, sugerindo que a rotulagem automática desses sinais ainda não está suficientemente madura para alimentar modelos supervisionados de forma confiável. Esses achados reforçam a necessidade de desenvolvimento de métodos híbridos — que combinem LLMs com fontes de conhecimento estruturadas (Zhou et al., 2021) — e maior investimento na qualidade da rotulagem para melhorar a performance dos classificadores.

Conclusões

Os resultados deste estudo indicam que as duas abordagens analisadas para a detecção de Fake News apresentaram desempenho compatível com outros trabalhos baseados em classificação sem treinamento prévio. No entanto, ao utilizar os Sinais de Credibilidade como variáveis preditoras em um modelo de classificação, observou-se desempenho inferior. Essa limitação pode estar relacionada à inconsistência na rotulagem gerada automaticamente pelo modelo a partir do prompt utilizado, evidenciando a necessidade de refinamento para aprimorar a qualidade desses dados.

Para desenvolvedores de sistemas de combate à desinformação, os resultados sugerem que os LLMs, no estado atual, ainda não constituem uma solução autônoma e confiável para detecção automática de desinformação. Contudo, podem ser explorados como ferramentas auxiliares na etapa de anotação, especialmente se combinados com processos de revisão humana e estratégias de refinamento dos prompts. Ademais, o uso dos sinais de credibilidade como features ainda exige validação, mas representa uma via promissora para desenvolvimento de modelos mais interpretáveis e alinhados a critérios jornalísticos e linguísticos.

Por fim, destaca-se que a escolha dos modelos empregados foi motivada pelo baixo custo computacional em comparação com alternativas mais sofisticadas. Assim, recomenda-se que trabalhos futuros investiguem a eficácia da abordagem baseada em Sinais de Credibilidade

na detecção de Fake News, bem como explorem a possibilidade de incluir ou excluir determinados sinais para otimizar o desempenho do modelo, em conjunto com modelos mais avançados de linguagem.

Referências

Abu Salem, F. K., Al Feel, R., Elbassuoni, S., Jaber, M. & Farah, M. (2019). FA KES: A Fake News Dataset around the Syrian War. In Proceedings of the International AAAI Conference on Web and Social Media, 13(01), 573-582.

Afroz S, Brennan, M., and Greenstadt, R.. 2012. Detecting hoaxes, frauds, and deception in writing style online. In 2012 IEEE Symposium on Security and Privacy, pages 461–475. IEEE.

Allcott, H.; & Gentzkow, M. Social Media and Fake News in the 2016 Election. Journal of Economic Perspectives, v. 31, n. 2, p. 211-236, 2017.

Chen, M.; Roberts, N.; Bhatia, K.; Wang, J.; Zhang, C.; Sala, F.; & Ré, C. (2023). Skill-it! A data-driven skills framework for understanding and training language models. In Proceedings of the 36th Conference on Neural Information Processing Systems (NeurIPS 2023).

Dufraisse, E., Treuillier, C., Brun, A., Tourille, J., Castagnos, S., & Popescu, A. (2022). Don't burst blindly: For a better use of natural language processing to fight opinion bubbles in news recommendations. In Proceedings of the LREC 2022 workshop on Natural Language Processing for Political Sciences, pages 79–85, Marseille, France. European Language Resources Association.

Giachanou A., Rosso, P., and Crestani, F. (2019). Leveraging emotional signals for credibility detection. In Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval, SIGIR'19, page 877–880, New York, NY, USA. Association for Computing Machinery.

Harris, R. Evaluating Internet research sources Disponível em: <<http://www.virtualsalt.com/evalu8it.htm>>. Acesso em: 10 outubro 2024.

Horne, B. D.; Adalı, S. This Just In: Fake News Packs a Lot in Title, Uses Simpler, Repetitive Content in Text Body, More Similar to Satire than Real News. In Proceedings of the International AAAI Conference on Web and Social Media, v. 11, n. 1, p. 759-766, 2017.

Leite, J. A., Razuvayevskaya, O., Bontcheva, K., & Scarton, C. (2025). Weakly supervised veracity classification with LLM-predicted credibility signals. EPJ Data Science, 14(1), 16.

Levenshtein, V. I. (1966). Binary codes capable of correcting deletions, insertions, and reversals. Soviet Physics Doklady, 10, 707-710.

Monteiro, R.A., Santos, R.L.S., Pardo, T.A.S., de Almeida, T.A., Ruiz, E.E.S., Vale, O.A. (2018). Contributions to the Study of Fake News in Portuguese: New Corpus and Automatic Detection Results. In: Villavicencio, A. et al. (eds) Computational Processing of the Portuguese Language. PROPOR 2018. Lecture Notes in Computer Science, vol 11122. Springer, Cham.

Paixão, M., Lima, R., & Espinasse, B. (2020, December). Fake news classification and topic modeling in Brazilian Portuguese. In 2020 IEEE/WIC/ACM International Joint Conference on Web Intelligence and Intelligent Agent Technology (WI-IAT) (pp. 427-432). IEEE.

Shu, K.; Sliva, A.; Wang, S.; Tang, J.; Liu, H. Fake News Detection on Social Media: A Data Mining Perspective. ACM SIGKDD Explorations Newsletter, v. 19, n. 1, p. 22-36, 2017.

YANG-AISUITE. Yang AI Suite: unified interface to multiple Generative AI providers. Disponível em: <https://github.com/andrewyng/aisuite>. Acesso em: 06 abr. 2025.

Zhou, X.; Zafarani, R. A Survey of Fake News Detection Approaches: Data Mining Perspective. ACM Computing Surveys (CSUR), v. 53, n. 5, p. 1-40, 2020.

Apêndice

Tabela 1: Prompts Utilizados para cada Sinal de Credibilidade

Sinal de Credibilidade	Prompt Utilizado
Evidência	Does the article present any supporting evidence or arguments to substantiate its claims?
Viés	Does the article exhibit any explicit biases in its content, tone, or perspective?

Inferência	Does the article make claims about correlation and causation?
Afirmações Explicitamente Não Verificadas	Does the article contain claims that are explicitly unverified?
Perspectiva Pessoal	Does the article express the author's opinion on the subject?
Valência Emocional	Is the language in the article extremely negative or extremely positive instead of neutral?
Linguagem Polarizada	Does the article make use of polarising terms or make divisions into sharply contrasting groups or sets of opinions or beliefs?
Chamada para Ação	Does the article contain language that can be understood as a call to action, requesting readers to follow through with a particular task or telling readers what to do?
Citação de Especialista	Does the article cite one or more experts in the subject?
Citação de Documentos	Does the article cite one or more studies or documents?
Crebilidade da Fonte Citada na Notícia	Does the article cite sources that are generally considered credible?
Grafia Incorreta	Does the article have significant misspellings and/or grammatical errors?
Tom Informal	Does the article make use of all caps or consecutive exclamation or question marks?
Incivilidade	Does the article make use of stereotypes and generalizations of groups of people?
Impolidez	Does the article contain insults, name-calling, or profanity?
Sensacionalismo	Does the article make use of sensationalist claims?
Organização com Baixa Credibilidade	This article was posted by a media outlet called {organization_name}. Is this source known for publishing false, unverified, or propagandistic articles?
Reportado por Outras Fontes	Was the story on this article reported by other reputable media outlets?

Fonte: <https://github.com/w3c/credweb>

Repositório no GitHub com o código do projeto:

https://github.com/Rafaellfig/detecting_fake_news_with_LLMs

Tabela 2: Conjunto completo de respostas obtidas no modelo Gemini 1.5-Flash para uma única amostra da base Fake.Br Corpus

Sinal de Credibilidade	Resposta	Rótulo
Evidência	No, the article provides no supporting evidence or arguments to substantiate its claims. It relies entirely on assertions and loaded language ("declara guerra," "salva criminosos," "destruir o judiciário"). Phrases like "A Globo News informou agora pouco" cite a news source but don't provide specifics like the time of the report or a link to verify the claim. The claim that Renan Calheiros changed his mind about voting on the project is presented as fact without any evidence of his previous statement or the context of his change of heart. The overall tone is highly accusatory and lacks any objective verification.	No
Viés	Yes, the article exhibits significant bias. The language used is highly charged and emotionally loaded, clearly framing Renan Calheiros' actions in a negative light. Phrases like "declara guerra ao judiciário" (declares war on the judiciary), "salva criminosos" (saves criminals), "destruir o judiciário" (destroy the judiciary), and the description of the vote as happening "na calada da noite" (in the dead of night) all contribute to a negative and suspicious portrayal of Renan Calheiros and his motives. [...]	Yes
Inferência	Yes, the article implies a causal relationship between Renan Calheiros' actions and his intent to "destroy the judiciary." The phrasing "Renan quer destruir o judiciário" (Renan wants to destroy the judiciary) directly follows the description of his actions regarding the anti-corruption project. This creates an implication that his actions (pushing for the urgent approval of the bill) *cause* the destruction of the judiciary. [...]	Yes
Afirmações Explicitamente Não Verificadas	Yes, the article contains several explicitly unverified claims. [...] While the article mentions Globo News as a source for some information, it doesn't provide specific quotes or details to verify the claims made. The overall tone is highly opinionated and lacks the neutral reporting needed for verification.	Yes
Perspectiva Pessoal	Yes, the article strongly expresses the author's opinion on the subject. Phrases like "declara guerra ao judiciário" (declares war on the judiciary), "salva criminosos" (saves criminals), "quer destruir o judiciário" (wants to destroy the judiciary), and the description of the vote as happening "na calada da noite" (in the dead of night) all carry negative connotations and clearly indicate the author's disapproval of Renan Calheiros' actions and motivations. The phrasing is biased and presents a negative portrayal of Renan Calheiros' intentions.	Yes
Valência Emocional	The language in the article is extremely negative. Words and phrases like "declara guerra ao judiciário" (declares war on the judiciary), "salva criminosos" (saves criminals), "destruir o judiciário" (destroy the judiciary), and the description of the vote as happening "na calada da noite" (in the dead of night) all contribute to a highly critical and biased portrayal of Renan Calheiros and his actions. The article uses loaded language to paint a picture of malicious intent and underhanded tactics. There is no attempt at neutrality or balanced reporting.	Yes

Linguagem Polarizada	Yes, the article uses highly polarizing terms and creates sharp divisions. Phrases like "declara guerra ao judiciário" (declares war on the judiciary), "salva criminosos" (saves criminals), "destruir o judiciário" (destroy the judiciary), and "articula uma reação à Lava Jato" (orchestrates a reaction to Lava Jato) are all highly charged and frame Renan Calheiros' actions in an extremely negative light. [...] The article doesn't present a balanced view; it presents a strongly negative portrayal of Renan Calheiros' actions and intentions.	Yes
Chamada para Ação	No, the article doesn't explicitly contain a call to action instructing readers to perform a specific task. While it describes Renan Calheiros' actions and intentions as aggressive ("declara guerra," "quer destruir"), it doesn't directly tell readers to do anything. The article reports on events and opinions, but it doesn't solicit any particular action from its audience.	No
Citação de Especialista	No, the article does not cite any experts. It presents assertions as facts without attribution to any legal scholars, political analysts, or other individuals with relevant expertise on the subject of the judiciary, anti-corruption legislation, or the political maneuvering described. The phrases "A Globo News informou agora pouco" and "Mais cedo, ele disse" indicate sources, but not expert sources. Globo News is a news organization, not an expert in legal matters.	No
Citação de Documentos	No, the provided text does not cite any studies or documents. It's a news report presenting claims and opinions, but it lacks any references to supporting evidence like studies, official reports, or legal documents. The phrases used are highly charged ("declara guerra," "salva criminosos," "destruir o judiciário") and present opinions rather than verifiable facts.	No
Creibilidade da Fonte Citada na Notícia	The article mentions Globo News as a source, which is a generally credible and well-known Brazilian news organization. However, the article itself presents information as fact without providing specific details like the time of the Globo News report or a link to the report. The lack of specific sourcing weakens the credibility of the claims made, even though Globo News itself is a credible source. The article relies heavily on unsubstantiated claims and strong, potentially biased language ("declarar guerra," "destruir o judiciário," "salva criminosos"). Therefore, while one source is named, the overall sourcing is weak and insufficient for objective verification.	Abstain
Grafia Incorreta	Yes, the article has several grammatical errors and stylistic issues, though not necessarily misspellings in the traditional sense. The phrasing is informal and sensationalistic, lacking the precision expected in journalistic writing. Specific examples include: * ***"Renan declara guerra ao judiciário"***: While grammatically correct in Portuguese, the phrasing is hyperbolic and lacks the neutrality expected in factual reporting. "Declares war" is an inflammatory term. [...] The overall tone is opinionated and lacks the objectivity expected in a news report. While the words themselves may not be misspelled, the sentence structure and word choices contribute to a lack of clarity and journalistic integrity.	Yes
Tom Informal	Yes, the article uses all caps in "Renan declara guerra ao judiciário". It does not use consecutive exclamation or question marks.	Yes

	The article doesn't explicitly use stereotypes of specific groups of people in the traditional sense (e.g., racial or ethnic stereotypes). However, it does employ generalizations and potentially inflammatory language that could be interpreted as stereotyping by association.	
Incivilidade	The phrase "projeto que 'salva criminosos'" ("project that 'saves criminals'") is a generalization. It doesn't offer specifics about the project's content, instead relying on a loaded phrase to create a negative impression of it and those who support it. This implicitly paints those who support the project as being in favor of criminals, a broad and potentially unfair generalization. [...] Therefore, while not using explicit stereotypes, the article uses loaded language and generalizations to create a negative portrayal of Renan Calheiros and those who support the mentioned project, potentially leading to the stereotyping of these individuals by association.	Yes
Impolidez	Yes, the article contains insults and name-calling. Phrases like "declara guerra ao judiciário" (declares war on the judiciary), "salva criminosos" (saves criminals), and "quer destruir o judiciário" (wants to destroy the judiciary) are highly charged and constitute strong accusations, bordering on insults. While not profanity in the strictest sense, the language is inflammatory and clearly intended to disparage Renan Calheiros and his actions.	Yes
Sensacionalismo	Yes, the article employs several sensationalist claims. Phrases like "declara guerra ao judiciário" (declares war on the judiciary), "salva criminosos" (saves criminals), "quer destruir o judiciário" (wants to destroy the judiciary), and "na calada da noite" (in the dead of night) are all designed to evoke strong emotional responses and present a biased, negative portrayal of Renan Calheiros' actions. These phrases lack the neutrality expected in objective journalism and instead aim to inflame the reader's opinion. [...]	Yes
Organização com Baixa Credibilidade	I cannot directly access external websites or specific files online, including the URL you provided. Therefore, I cannot assess the reputation of diariodobrasil.org for publishing false, unverified, or propagandistic articles. To determine the reliability of this source, you would need to research it independently. Look for information about the website's history, ownership, fact-checking record, and any critiques or analyses of its reporting from reputable media analysis organizations. Consider whether it has a history of bias or promoting a particular agenda.	Abstain
Reportado por Outras Fontes	The provided text is a short, opinionated piece, not a neutral news report. It lacks attribution to specific sources beyond "Globo News," which is named but without a link to a specific report. [...] To determine if the core claims (Renan Calheiros' actions regarding the anti-corruption bill and his alleged change of stance) were reported by other reputable sources, further investigation using searches on reputable news organizations covering Brazilian politics would be necessary. Simply put, based on this text alone, we cannot confirm if the story was reported elsewhere.	Abstain

Fonte: Resultados originais da pesquisa